

EM for old faithful dataset

EM algorithm:

重複步驟直到參數收斂{

(E – step) For each i , set

$$Q(\theta|\theta^{(t)}) = E_y[\log p(x, y|\theta) | x, \theta^{(t)}]$$

(M – step) Set

$$\theta^{(t+1)} = \arg \max_{\theta} Q(\theta|\theta^{(t)}) = \arg \max_{\theta} \sum_{i=1}^n \sum_{y_i=1}^k [\log(\alpha_{y_i} p(x_i|y_i, \theta)) p(y_i|x_i, \theta^{(t)})]$$

}

其中 (E-step) 為

$$\begin{aligned} Q(\theta|\theta^{(t)}) &\equiv E_y[\log p(x, y|\theta) | x, \theta^{(t)}] \\ &= E\left[\sum_i \log(p(y_i|\theta)p(x_i|y_i, \theta)) | x, \theta^{(t)}\right] \\ &= \sum_{i=1}^n E_y[\log(\alpha_{y_i} p(x_i|y_i, \theta)) | x, \theta^{(t)}] \\ &= \sum_{i=1}^n \sum_{y_i=1}^k [\log(\alpha_{y_i} p(x_i|y_i, \theta)) p(y_i|x_i, \theta^{(t)})] \\ &= \sum_{i=1}^n \sum_{j=1}^k [\log(\alpha_j \phi(x_i|\mu_j, \Sigma_j)) p(y_i = j|x_i, \theta^{(t)})] \end{aligned}$$

Recall $\theta = \{\alpha_j, \mu_j, \Sigma_j; j = 1, \dots, k\}$

目的: 找到使 Q 函數的最大值參數

(M-step)

我們從(E-step)得到概似函數，並將其最大概似函數的 MLE 計算出來，得到的結果如下

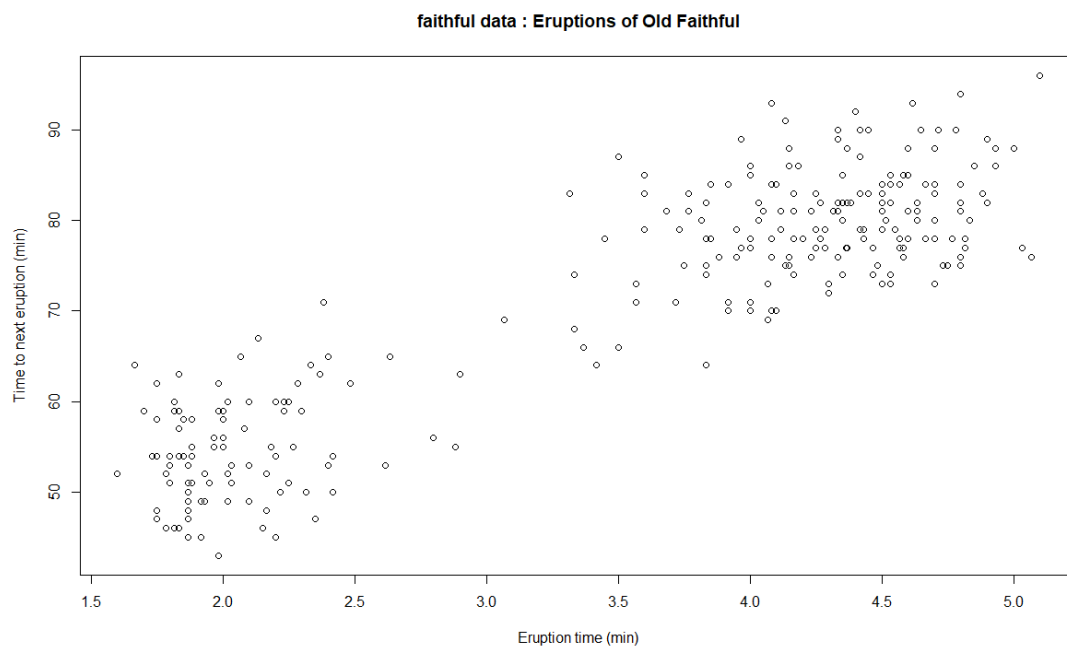
$$\begin{aligned}\alpha_j^{(t+1)} &= \frac{\sum_{i=1}^n p(y_i = j | x_i, \theta^{(t)})}{n} \\ \mu_j^{(t+1)} &= \frac{\sum_{i=1}^n x_i p(y_i = j | x_i, \theta^{(t)})}{\sum_{i=1}^n p(y_i = j | x_i, \theta^{(t)})} \\ \Sigma_j^{(t+1)} &= \frac{\sum_{i=1}^n (x_i - \mu_j^{(t)})(x_i - \mu_j^{(t)})^T p(y_i = j | x_i, \theta^{(t)})}{\sum_{i=1}^n p(y_i = j | x_i, \theta^{(t)})}\end{aligned}$$

結論：

我們發現兩步驟相同的函數為 $p(y_i = j | x_i, \theta^{(t)})$ ，也就是說我們在撰寫 EM 演算法的時候，我們只要根據每次迭代得到新的參數，在給定原本的樣本下，把每一次隱藏變數的條件分配計算出來，並帶入我們(M-step)的結果算出新的參數，經過數次迭代後，就能找到收斂的參數。

Old Faithful dataset :

資料為美國黃石國家公園週期性噴發時間及等待時間資料(成對共 272 筆資料)



由上圖我們可以發生資料呈現為兩群的分佈，所以此題我們使用的分配為兩個混合的二元常態分配，並使用 EM 演算法來進行參數估計

$$(x_i, y_i) \sim a \text{ mix of } N(\mu_j, \Sigma_j), i = 1, \dots, n, j = 1, 2, \mu_j = (\mu_{j1}, \mu_{j2})^T$$

我們先計算樣本中的平均數與變異數

	Eruption(min)	Waiting(min)
Means	3.487783	70.89706
Covariance matrix	$\begin{bmatrix} 1.302728 & 13.97781 \\ 13.97781 & 184.8233 \end{bmatrix}$	


根據上圖，我們選取下列數值作為起始值

	Dis.1	Dis.2
Weights α_i	$\alpha_1 = 0.5$	$\alpha_2 = 0.5$
Means μ_j	$\mu_1 = (2, 60)$	$\mu_2 = (4, 80)$
Covariance matrix Σ_j	$\begin{bmatrix} 1 & 7 \\ 7 & 100 \end{bmatrix}$	$\begin{bmatrix} 2 & 20 \\ 20 & 200 \end{bmatrix}$


經由 EM 演算法迭代 30 次後，兩分配的估計參數如下：

	Dis.1	Dis.2
Weights α_i	$\alpha_1 = 0.3558854$	$\alpha_2 = 0.6441146$
Means μ_j	$\mu_1 = (2.036421, 54.478880)$	$\mu_2 = (4.289688, 79.968413)$
Covariance matrix Σ_j	$\begin{bmatrix} 0.6991678 & 0.4400356 \\ 0.4400356 & 34.0510792 \end{bmatrix}$	$\begin{bmatrix} 0.1709121 & 0.9456217 \\ 0.9456217 & 36.2489521 \end{bmatrix}$

接著我們根據迭代後得到的參數，將其二元常態機率密度投影在二維平面上



我們將兩分配一同繪製在原始的圖表上



以上為從 EM 演算法估計出參數所繪製的結果
30 次迭代過程的動態 gif 檔：[網址](#)